

06 GPU 计算与原生核心

让每一次科学计算，都发生在离思想最近的地方

Ergalics Studio 的计算加速由两层构成：Rust 编译的 WebAssembly 原生核心（`native/ergalics-core`）提供设备管理与计算内核的参考实现；宿主侧的计算服务（`src/core/gpu.ts`、`src/core/compute.ts` 与 `src/core/gpu-kernels.ts`）把这套能力以统一接口暴露给插件与领域内核，并在 WASM...



官网

snowleopard-io.github.io/ErgalicsStudio



GitHub

github.com/SnowLeopard-io/ErgalicsStudio



Gitee

gitee.com/cnt-code/ergalics-studio

本篇章节

一 Rust 原生核心

二 宿主侧计算服务

三 可复用 WGSL 内核

四 端到端数值验证

五 构建与降级说明

目 录

一、Rust 原生核心

二、宿主侧计算服务

三、可复用 WGSL 内核

3.1 引擎选择与数据规模阈值

四、端到端数值验证

五、构建与降级说明

03

04

06

09

09

09

当 WebGPU（或 WASM 模块）不可用时，`api.gpu` 为 `undefined`，插件回退到 CPU 实现——行为一致，不要求 GPU 存在。

Ergalics Studio 的计算加速由两层构成：Rust 编译的 WebAssembly 原生核心（`native/ergalics-core`）提供设备管理与计算内核的参考实现；宿主侧的计算服务（`src/core/gpu.ts`、`src/core/compute.ts` 与 `src/core/gpu-kernels.ts`）把这套能力以统一接口暴露给插件与领域内核，并在 WASM 或 WebGPU 缺失时逐级降级到纯 CPU 路径。

一 Rust 原生核心

`native/ergalics-core`（crate 版本 0.1.0，edition 2021，`crate-type = ["cdylib", "rlib"]`）编译目标为 `wasm32-unknown-unknown`，经 `wasm-bindgen 0.2` 绑定到 `src/native`（构建产物，不入库）。WebGPU 绑定依赖 `web-sys` 的实验性 GPU API 面，通过 Cargo feature 显式开启。依赖为 `wasm-bindgen`、`wasm-bindgen-futures`、`js-sys`、`web-sys`、`console_error_panic_hook`、`serde` 与 `serde_json`；release profile 开启 `lto`、`codegen-units = 1` 与 `opt-level = 3`。Rust 源码按职责分为五个模块：

源文件	职责
lib.rs	对外导出、版本查询（ <code>core_version</code> ）与初始化
device.rs	GpuDeviceManager 与 GpuInfo：适配器与设备获取， <code>webgpu_available</code> 探测，带 CPU 回退选项
buffer.rs	GpuBuffer：以显式 usage 掩码创建存储 / 只读 / 均匀缓冲，write 上传、read 经专用回读缓冲读回
compute.rs	KernelDescriptor 与 BindingDescriptor、ComputeKernel 编译、绑定组物化与 dispatching，ComputeQueue 封装
utils.rs	detect_file_kind 等辅助（基于魔数的文件类型检测）与日志

面向 JavaScript 的暴露面：

能力	说明
GpuDeviceManager / GpuInfo	适配器与设备获取，带 CPU 回退选项； <code>webgpu_available</code> 供降级决策
GpuBuffer	显式 usage 掩码的缓冲创建（ <code>create_storage</code> 、 <code>create_readable_storage</code> 、 <code>create_uniform</code> ）、上传与经回读缓冲的读取
KernelDescriptor / BindingDescriptor	描述计算内核与缓冲绑定（ <code>uniform</code> 、 <code>storage</code> 、 <code>read-only-storage</code> ，动态偏移与最小绑定尺寸）

能力	说明
ComputeKernel::compile	从绑定描述符构建真实的 GPUBindGroupLayout，编译 WGSL 模块并创建管线
ComputeKernel::bind_group	从保留的布局物化绑定组（第 i 个缓冲对应第 i 个绑定）
ComputeKernel::run	一次调用完成绑定组、dispatch 与提交；dispatch 方法留给宿主自管命令编码器
compilation_info	异步暴露 WGSL 编译诊断（错误或警告加行列号）
detect_file_kind	基于魔数的文件类型检测，供加载器使用

☐ 宿主侧计算服务

`src/core/gpu.ts` 持有适配器与设备生命周期（`initGpu` / `getGpuBackend` / `resetGpu` / `subscribeGpu`），负责 CPU 回退与显存不足跟踪。其上的 `src/core/compute.ts` 是面向插件的计算面（即 `PluginApi.gpu`）：`createBuffer`、`write`、`read`、`compileKernel`、`compilationInfo` 与一次性 `run`。路由逻辑：




图 1

当 WebGPU（或 WASM 模块）不可用时，`api.gpu` 为 `undefined`，插件回退到 CPU 实现——行为一致，不要求 GPU 存在。

这一设计保证开发与生产环境的加速计算均可用：Rust 核心始终是参考引擎，WebGPU 直连是加速路径，而每个内置插件的 CPU 回退跑的是与 GPU 内核数学一致的实现。

可复用 WGSL 内核

`src/core/wgsl.ts` 收纳可复用的 WGSL 计算内核，并配套与内核数学一致的宿主侧打包 / 解包辅助函数供 CPU 回退使用。当前共 **14 个内核**：

内核	数学内容	主要使用方
particleKernelWGSL	交错式 [x, y, vx, vy] 单缓冲积分	粒子插件
nbodyKernelWGSL	三维全对引力 $O(N^2)$ 直接求和	N-Body 引力插件
histogramKernelWGSL	分箱计数 + 对数刻度	直方图插件与统计区块
heatmapKernelWGSL	网格标量到颜色映射 (viridis 停靠点)	热力图插件
pointCloudKernelWGSL	点云投影与密度输出	点云插件、百万级点云增强
fluidCollideKernelWGSL	D2Q9 格子 Boltzmann 碰撞	流体插件
fluidStreamKernelWGSL	D2Q9 迁移	流体插件
fluidCurlKernelWGSL	涡量计算 (涡街可视化)	流体插件
waveKernelWGSL	二维波动方程 leapfrog 时间推进	波动方程插件
matmulKernelWGSL	分块矩阵乘法 (TILE = 16)	领域内核线性代数加速
fftKernelWGSL	按级迭代的基 2 FFT (最大 N = 4096)	信号实验室
kmeansKernelWGSL	K-means 指派与质心累加	数据画像与聚类

内核	数学内容	主要使用方
binningKernelWGSL	键值分箱聚合 (sum / mean / count)	分箱统计与扫描
spmvKernelWGSL	稀疏矩阵-向量乘 (CSR 行式逐步)	宿主侧稀疏线性代数内核库 (暂无内置插件直接调用; em-eigensolver 改在 Pyodide 上以 NumPy 求解)

两种典型的内核调用路径：

- 1. **单缓冲路径**（粒子演示）：上传交错式数据加均匀参数，dispatch WGSL 积分器，读回结果并上报真实 GPU 时间。
- 2. **乒乓缓冲路径**（N-Body 演示）：成对缓冲交替读写，每个积分步完全留在设备上，无逐步回读开销。

以 N-Body 为例的逐步流程：






图 2



N-Body 引力在 GPU 上的全对求和：数天体绕中心质量的三维引力轨迹，WGSL 内核计算并一次性读回交给 Three.js 渲染。



格子 Boltzmann 流体：WGSL 编译器推导 D2Q9 碰撞 / 流 / 涡量三内核并逐步计算，绕翼流场与卡门涡街清晰可见，小规模自动回退 CPU。

3.1 引擎选择与数据规模阈值

GPU 的收益来自算力，但上传与回读有固定开销，小规模数据在 GPU 上反而更慢。`src/core/gpu-kernels.ts` 因此提供统一分派层与一组数据规模阈值，`auto` 模式下低于阈值自动走 CPU：

内核	阈值单位	阈值
matmul	输出元素数 (m × n)	16384 (128 × 128)
fft	复数样本数	1024
kmeans	点数	2048
binning	行数	10000

阈值判断还会叠加实时设备可用性 (`getGpuBackend()`)，并把引擎选择写入运行记录，使"这一次是谁在算"可追溯。`src/core/pointcloud-gpu.ts` 在此之上提供百万级点云的预算控制与自动降采样策略，`src/core/mesh3d.ts` 提供三维网格数据管线的纯函数实现。

四 端到端数值验证

GPU 路径不是摆设：`verify-webgpu` 端到端套件在无头 Edge (SwiftShader 软件渲染) 中驱动真实 WebGPU 通路，用数值基准比较 GPU 结果与 CPU 积分器，误差要求在约 2e-6 以内；另有应用集成步骤点击粒子插件并断言出现 wasm 引擎的 GPU 提示。单元测试层覆盖每个 WGSL 模板的生成、参数打包、输出尺寸与 CPU 回退的一致性，以及 GPU 与 CPU 两条路径的数值一致性比对 (内核级与领域级两层)。

五 构建与降级说明

构建命令链为：先执行 `build:wasm` 将 Rust 核心编译进 `src/native`，再进行类型检查与 Vite 生产构建。只构建前端可跳过 WASM 步骤 (`build:web`)。持续集成环境不安装完整 Rust 工具链，由存根生成脚本 (`make-wasm-stub.mjs`) 提供占位 WASM 模块。

当 WASM 模块缺失时前端优雅降级：欢迎页硬件自检会如实报告 WebGPU、WASM 与 IndexedDB 的可用性；计算路由自动改走原生 WebGPU API 或 CPU 实现；插件在无 GPU 环境下以 CPU 完成同样的数学，行为一致。三级降级路径总结：

档位	条件	计算路径
参考引擎	WASM 模块已加载	Rust 原生核心
加速路径	WebGPU 可用 (含经 WASM 或直连)	GPU 内核
兜底路径	两者皆缺	与内核数学一致的 CPU 实现

让每一次科学计算，

都发生在离思想最近的地方

Ergalics Studio 把复杂度收进浏览器：安装、配置与数据搬运都不该出现在科研的路上。打开即可计算，数据留在本机，四种工作模式共享同一份数据——一张图、一条流程与一行代码，都是同一次工作的不同表达。

工具越安静，思想就越清楚。我们做的每一处取舍，都为了把注意力还给问题本身。

作者 [SnowLeopard-io](#) github.com/SnowLeopard-io